Классификация фокальной дистонии по данным МРТ

Рада Лихачева

Аннотация

В работе рассматривается задача классификации фокальной дистонии по структурным магнитно-резонансным изображениям головного мозга с использованием предобученной модели BrainIAC. Цель исследования: адаптировать модель для различения пациентов с дистонией верхней конечности и здоровых участников на открытом наборе данных OpenNeuro ds006395. Исследование предусматривает дообучение энкодера и сравнение с классификатором на признаках замороженной модели. В выполненном базовом эксперименте на 66 участниках использованы 768-мерные представления BrainIAC и логистическая регрессия; при стратифицированной пятикратной кросс-валидации получены сбалансированная точность 0,562 и ROC-AUC 0,569. Эти значения рассматриваются как предварительная точка отсчёта; устойчивое преимущество над случайным уровнем пока не установлено. Дальнейшие эксперименты направлены на оценку вклада дообучения в качество и устойчивость классификации при ограниченном объёме данных.

Ключевые слова: фокальная дистония; структурная МРТ; BrainIAC; перенос обучения; классификация.

1 Введение

Дистония - двигательное расстройство, характеризующееся устойчивыми или периодически возникающими патологическими движениями, позами либо их сочетанием [29]. При фокальной форме нарушения ограничены одной областью тела; в настоящей работе рассматривается дистония верхней конечности. Поиск количественных нейровизуализационных признаков заболевания мотивирует разработку методов автоматической классификации пациентов и здоровых участников. Структурная магнитно-резонансная томография позволяет исследовать анатомические характеристики головного мозга, однако выделение признаков, пригодных для индивидуального предсказания, остаётся сложной задачей. Цель настоящего исследования - адаптация предобученной модели BrainIAC для классификации дистонии верхней конечности по T1-взвешенным изображениям.

Существующие исследования используют морфометрические характеристики коры и подкорковых структур, показатели диффузии и функциональной связности. При этом результаты зависят от клинической формы и выбранного способа анализа. Так, de Faria и соавторы [1] не обнаружили значимых структурных различий между пациентами с дистонией верхней конечности и здоровыми участниками, тогда как анализ стриарных компартментов выявил особенности, различающиеся между подтипами фокальной дистонии [3]. Отдельное направление связано с непосредственной классификацией изображений: модель DystoniaNet использует трёхмерную свёрточную сеть для распознавания дистонии по структурной МРТ [6]. Таким образом, существующая литература обосновывает применение машинного обучения, но не устанавливает универсальную переносимость полученных решений между формами заболевания.

Основные ограничения этой задачи связаны с небольшими размеченными выборками, высокой размерностью изображений и неоднородностью клинических групп. Наличие групповых различий само по себе не гарантирует точной классификации нового участника, а их отсутствие не исключает информативности многомерного представления. Кроме того, при малом числе наблюдений качество существенно зависит от разбиения данных, а утечки при обработке или выборе признаков могут приводить к завышенным оценкам [20, 22]. Поэтому

результаты, полученные для других форм дистонии и при иных процедурах тестирования, требуют отдельной проверки на целевой выборке.

В настоящей работе рассматривается перенос обучения с использованием BrainIAC - модели анализа МРТ головного мозга, основанной на трёхмерном Vision Transformer и контрастивном самообучении [9]. Предлагается адаптировать её представления к различению пациентов с дистонией верхней конечности и здоровых участников и сопоставить дообучение с линейным классификатором на признаках замороженного энкодера. Выбор такого подхода позволяет использовать знания, полученные при предварительном обучении на крупной коллекции МРТ, и проверить необходимость обновления представлений на целевых данных. При этом преимущество дообучения не предполагается заранее: изменение предобученных признаков может снижать обобщающую способность модели [19].

Исследование сосредоточено на сравнении режимов адаптации BrainIAC в едином протоколе классификации. Для вычислительных экспериментов выбран открытый набор OpenNeuro ds006395; используются структурные T1-взвешенные изображения пациентов с дистонией верхней конечности и здорового контроля. Предусматриваются проверка качества изображений, согласованная предобработка, обучение классификаторов и оценка на одинаковых разбиениях по участникам. Подбор гиперпараметров выполняется внутри обучающих подвыборок, а основными метриками служат сбалансированная точность и площадь под ROC-кривой. Такое сравнение направлено на оценку вклада дообучения и устойчивости классификации при ограниченном объёме данных.

2 Обзор литературы

2.1 Структурные и функциональные признаки дистонии

Нейровизуализационные исследования дистонии рассматривают изменения корковых, подкорковых структур и связей между ними. Однако обнаруживаемые особенности зависят от клинической формы, модальности МРТ и способа обработки. В исследовании структурных изменений при цервикальной и генерализованной дистонии анализировались толщина коры, объёмы и форма подкорковых структур [5]. Его результаты характеризуют эти клинические группы, но не устанавливают универсальный признак, одинаково применимый ко всем формам дистонии.

Для настоящей работы особенно значимо исследование de Faria и соавт. по дистонии верхней конечности [1]. Авторы проанализировали структурные T1-взвешенные изображения и диффузионные данные 28 пациентов и 29 здоровых участников. После морфометрического и диффузионного анализа значимых межгрупповых различий обнаружено не было. Этот результат ограничивает ожидания относительно выраженности структурного сигнала, но сам по себе не исключает классификацию на основе сочетания нескольких признаков. Проверка гипотезы о средних групповых различиях и оценка предсказания для нового участника являются различными статистическими задачами.

В анализе 91 участника, включавшем дистонию верхней конечности, цервикальную дистонию и контроль, выявлены зависимые от подтипа особенности стриарных компартментов и белого вещества [3]. Отдельная работа исследует объёмы таламуса и его подразделений на данных ds006395 [4]. Эти результаты показывают важность локальных представлений и клинической неоднородности. При этом повторные анализы одного открытого набора нельзя считать независимыми внешними подтверждениями. Кроме того, признаки диффузионной МРТ не доступны автоматически модели, использующей только T1-изображения.

Функциональные исследования расширяют представление о сетевых изменениях. Guo и соавт. сопоставили морфометрию и функциональную связность у 35 пациентов с цервикальной дистонией и 28 здоровых участников [2]. Другие авторы использовали функциональную связность и региональную однородность для SVM-классификации [7, 8]. Эти исследования обосновывают интерес к индивидуальным предсказаниям, но их результаты не являются

прямым ориентиром качества классификации ULD по структурной T1-МРТ: отличаются заболевание, модальность и протокол оценки.

2.2 Прямая классификация по МРТ

Ключевой работой по классификации дистонии на структурных изображениях является DystoniaNet [6]. В ней трёхмерная свёрточная сеть обучалась извлекать признаки непосредственно из МРТ и формировать решение о принадлежности к клинической группе. Работа показывает, что постановка классификации дистонии по структурным изображениям уже существует; применение нейросети к этой задаче само по себе не составляет новизну.

Перенос опубликованного качества DystoniaNet на настоящую задачу ограничен различиями клинических форм, выборок и схем тестирования. В частности, сообщаемое авторами высокое качество на дополнительной пациентской выборке с возможностью направления на дополнительное обследование нельзя трактовать как обычную бинарную accuracy на смешанной выборке пациентов и контроля. Сравнение с новой моделью должно проводиться при одинаковых классах, метриках и независимых тестовых объектах.

Таким образом, DystoniaNet является ближайшим предметным предшественником. Прямое экспериментальное сравнение требует общей выборки, одинаковых целевых классов и процедуры оценки.

2.3 Предобученные модели и адаптация к новой задаче

Ограниченное количество размеченных МРТ мотивирует перенос представлений, обученных на более крупных коллекциях. Ранние подходы включают Med3D/MedicalNet, использующий предобучение трёхмерных сетей на нескольких медицинских задачах [15], и Models Genesis, где сеть обучается восстанавливать преобразованные фрагменты изображений [16]. Эти работы различаются целью обучения и исходными данными; их результаты обосновывают подход к переносу, но не доказывают эффективность для дистонии.

Трансформерные архитектуры развивают этот подход через представление изображения в виде последовательности пространственных патчей [18]. В медицинской визуализации Swin UNETR использует специальные задачи самообучения для трёхмерных изображений [17], а BrainSegFounder сочетает этапы предобучения для нейровизуализационной сегментации [10]. Успех сегментации не равнозначен успешной классификации клинических групп, поэтому эти модели рассматриваются как методический контекст и возможные будущие альтернативы.

Основой настоящего проекта выбрана BrainIAC [9]. В журнальной версии 2026 года модель использует трёхмерный ViT-B и контрастивное самообучение; авторы сравнивают адаптацию к нескольким задачам, включая linear probing и сквозное дообучение. Здесь важно опираться именно на журнальную версию: ранний препринт описывал иную конфигурацию модели и меньший набор задач. Оценка BrainIAC на исходных задачах не устанавливает её качество на ULD.

Современные альтернативы включают AnatCL, учитывающую анатомическую информацию при контрастивном обучении [11], 3DINO с самодистилляцией на разнородных объёмных данных [12] и BrainDINO, использующую срезовые представления и замороженный энкодер [13]. OpenMind предлагает открытые данные и стандартизированные условия изучения трёхмерного самообучения [14]. Эти работы показывают разнообразие переносимых представлений и необходимость сопоставимых условий оценки. В настоящем исследовании основное сравнение ограничено режимами адаптации BrainIAC.

Дообучение не гарантирует улучшения относительно замороженного энкодера. Kumar и соавт. показывают, что обновление предобученных представлений при сдвиге распределения может ухудшать обобщение [19]. Поэтому в нашей работе frozen baseline сохраняется как обязательная точка сравнения. Сравнение обучения головы, частичного и полного дообучения формирует проверяемую экспериментальную ось; преимущество одного режима должно быть установлено на целевой выборке.

2.4 Малые выборки, утечки данных и оценка качества

При небольшом числе участников оценка качества чувствительна к выбору разбиения. Varoquaux анализирует неопределённость кросс-валидации на малых выборках [20], а Vabalas и соавт. исследуют влияние процедуры валидации на оценку алгоритмов [24]. Поэтому единственное удачное разбиение не является достаточным подтверждением преимущества. При сравнении режимов адаптации нужно использовать одни и те же внешние folds и отделять подбор гиперпараметров от итоговой оценки.

Wen и соавт. проводят воспроизводимую оценку классификации по T1-МРТ и демонстрируют проблему утечек [21]. Отдельное экспериментальное исследование показывает искажение результатов при распределении срезов одного человека между обучением и тестированием [27]. Аналогичные проблемы отбора признаков и обработки данных исследуются в работах по коннектомному прогнозированию [22]. В нашем протоколе все изображения и производные одного участника должны оставаться внутри одного fold, а обучаемые преобразования должны оцениваться только по обучающей части.

Возраст, пол, размеры мозга и технические характеристики изображений могут быть источниками предсказательного сигнала, не совпадающего с клиническими различиями. Работа Snoek и соавт. обосновывает необходимость контроля конфаундеров внутри процедуры валидации [23]. Исследование воспроизводимости эмбеддингов при сканировании одних участников на разных сканерах представляет дополнительный современный контекст технической вариабельности [28].

Для сопоставления качества со случайным уровнем могут применяться перестановочные тесты [25]. При перестановке меток необходимо повторять весь обучаемый протокол, включая подбор гиперпараметров, если он проводился в основном эксперименте. Работа Marek и соавт. подчёркивает проблему воспроизводимости слабых межиндивидуальных brain–phenotype ассоциаций [26], однако её вывод о тысячах участников нельзя трактовать как универсальный минимальный объём для любой задачи классификации дистонии.

2.5 Вывод и место настоящей работы

В литературе уже представлены классификация дистонии по МРТ, анализ структурных особенностей ULD и перенос предобученных нейровизуализационных моделей. Следовательно, предполагаемый вклад настоящей работы следует формулировать на уровне конкретной адаптации и экспериментальной проверки: классификация ULD и здорового контроля по T1-МРТ с использованием BrainIAC и сравнением режимов обучения в едином протоколе.

Рабочая гипотеза состоит в том, что адаптация предобученных представлений к целевой клинической выборке может изменить качество классификации по сравнению с обучением линейного классификатора на замороженных признаках. Направление изменения заранее не фиксируется как установленный факт. Вклад исследования связывается со сравнением режимов адаптации на целевой задаче в едином протоколе оценки.

3 Постановка задачи

Рассматривается задача бинарной классификации пациентов с дистонией верхней конечности и здоровых участников по структурным T1-взвешенным МРТ головного мозга. Требуется построить классификатор на основе предобученной модели BrainIAC и сравнить использование замороженных представлений с адаптацией энкодера к целевой задаче.

3.1 Данные и обозначения

Пусть задана выборка

$$\mathcal{D} = \{(x_i, y_i)\}_{i=1}^{n},$$

где x_i - трёхмерное T1-взвешенное изображение одного участника, а $y_i \in \{0, 1\}$ - метка класса: $y_i = 0$ для здорового контроля и $y_i = 1$ для пациента с дистонией верхней конечности. В предварительном эксперименте использованы $n = 66$ участников: 37 здоровых и 29 пациентов. Участники с цервикальной дистонией в эту постановку не включаются.

Обозначим через T процедуру предобработки изображения, а через g_θ - энкодер BrainIAC с параметрами θ. Через S_{tr} обозначается стандартизация признаков, параметры которой оцениваются на обучающей части. Изображению сопоставляется вектор признаков

$$z_i = S_{\text{tr}}(g_\theta(T(x_i))) \in \mathbb{R}^{768}.$$

Линейный классификатор определяет вероятность положительного класса:

$$p_i = p_{\theta,w,b}(y_i = 1 \mid x_i) = \sigma(w^\top z_i + b), \qquad \sigma(t) = \frac{1}{1 + \exp(-t)},$$

где $w \in \mathbb{R}^{768}$ и $b \in \mathbb{R}$ - обучаемые параметры. В базовом эксперименте стандартизация применяется к признакам замороженного энкодера. Для сквозного дообучения может использоваться тождественное преобразование $S_{\text{tr}} = I$.

3.2 Критерий обучения

В качестве внутреннего критерия рассматривается взвешенная бинарная кросс-энтропия с L2-регуляризацией коэффициентов классификатора:

$$Q(\theta, w, b; \mathcal{D}_{\text{tr}}) = -\frac{1}{\sum_{i \in I_{\text{tr}}} a_{y_i}} \sum_{i \in I_{\text{tr}}} a_{y_i} \left[y_i \log p_i + (1 - y_i) \log(1 - p_i) \right] + \frac{\lambda}{2} \|w\|_2^2.$$

Здесь I_{tr} - индексы обучающих участников, $a_0, a_1 > 0$ - веса классов, вычисляемые по обучающей выборке, а $\lambda > 0$ определяет силу регуляризации. Нормировка записана для математического описания метода; соответствие λ параметру C зависит от нормировки функции потерь в реализации.

В базовом эксперименте параметры энкодера фиксируются на предобученных значениях θ_0, и решается задача

$$(w^*, b^*) = \arg\min_{w,b} Q(\theta_0, w, b; \mathcal{D}_{\text{tr}}).$$

На следующем этапе предполагается оптимизация также выбранного подмножества параметров энкодера:

$$(\theta^*, w^*, b^*) = \arg\min_{\theta \in \Theta_{\text{adapt}},\, w,b} Q(\theta, w, b; \mathcal{D}_{\text{tr}}),$$

где Θ_{adapt} задаёт режим адаптации: обновление выбранных блоков или всего энкодера с инициализацией θ_0. Дообучение энкодера является планируемой частью исследования.

3.3 Валидация и внешние критерии

Основные внешние критерии - сбалансированная точность и площадь под ROC-кривой. Для положительного класса «дистония» сбалансированная точность определяется как

$$\text{BA} = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right).$$

Дополнительно оцениваются accuracy, чувствительность, специфичность и матрица ошибок. Для бинарного решения в базовой логистической регрессии применяется стандартный порог 0,5; ROC-AUC оценивает ранжирование по вероятностям.

Предварительная оценка выполнена с помощью стратифицированной пятикратной кросс-валидации по участникам. Все изображения, производные данные и аугментации одного

человека должны оставаться внутри одного разбиения. Для последующего сравнения режимов используются одинаковые внешние разбиения; подбор гиперпараметров и ранняя остановка выполняются только внутри обучающей части.

Ограничения исследования включают небольшой объём выборки, использование одной модальности и отсутствие независимой внешней тестовой когорты. Качество внутри данной выборки не интерпретируется как подтверждение клинической диагностической готовности.

4 Базовый вычислительный эксперимент

4.1 Цель и конфигурация

Цель базового эксперимента - получить исходное качество классификации ULD и здорового контроля при использовании предобученных признаков BrainIAC без изменения весов энкодера. Этот результат служит точкой отсчёта для дальнейшего дообучения.

Использованы T1-взвешенные изображения 66 участников OpenNeuro ds006395 [30]: 29 пациентов с дистонией верхней конечности и 37 здоровых участников. Предварительная обработка включала приведение к ориентации RAS, изменение размера до $96 \times 96 \times 96$ вокселей и Z-нормализацию интенсивностей по ненулевым вокселям. Удаление тканей вне мозга, регистрация в стандартное пространство и N4-коррекция в этом запуске не выполнялись.

Для каждого изображения замороженный BrainIAC формировал 768-мерное представление. Классификация проводилась с использованием стандартизации признаков и логистической регрессии. Применялись $C = 0{,}1$, балансировка весов классов и ограничение в 3000 итераций оптимизации. Использовался StratifiedKFold с пятью разбиениями, перемешиванием и random_state=42.

Вектор признаков извлекался как первый токен патча на выходе энкодера, а не CLS-токен. StandardScaler обучался внутри каждого фолда. ROC-AUC рассчитан по объединённым out-of-fold вероятностям, а не усреднением значений отдельных фолдов.

4.2 Предварительные результаты

Метрика	Значение
Accuracy	0,576
Balanced accuracy	0,562
ROC-AUC	0,569

Матрица ошибок, сохранённая в выводе запуска:

Истинный класс	Предсказан HC	Предсказан ULD
HC	25	12
ULD	16	13

При положительном классе ULD чувствительность составляет $13/29 \approx 0{,}448$, а специфичность - $25/37 \approx 0{,}676$. Для сравнения, постоянное предсказание HC на этой выборке даёт accuracy $37/66 \approx 0{,}561$ и balanced accuracy 0,5. Это аналитическая контрольная величина, а не результат отдельно запущенного DummyClassifier.

Полученные значения близки к случайному уровню. Статистическая значимость отличия от нулевого уровня и устойчивость результатов по повторным разбиениям пока не установлены. Поэтому эксперимент рассматривается как предварительный baseline, подтверждающий работоспособность цепочки извлечения признаков и обучения классификатора, но не как свидетельство надёжной диагностической классификации.

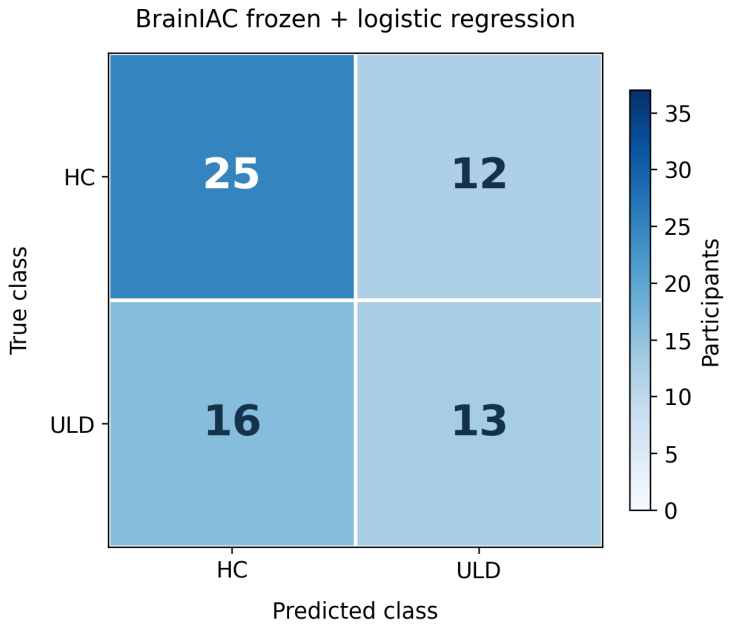


Рис. 1: Матрица ошибок базового классификатора. Строки - истинные классы, столбцы - предсказания.

5 Обсуждение и дальнейшая работа

Предварительный эксперимент демонстрирует работоспособность цепочки извлечения признаков и обучения классификатора, однако не подтверждает надёжного разделения клинических групп. Чувствительность к пациентам ниже специфичности к контролю, а accuracy лишь немного превышает результат постоянного предсказания наиболее частого класса. В этой ситуации основные выводы следует строить по сбалансированной точности, ROC-AUC и оценке неопределённости.

Ограничения включают малый размер выборки, упрощённую предобработку и отсутствие внешней тестовой когорты. Кроме того, ещё не выполнены анализ чувствительности к разбиениям и перестановочная проверка. Отдельной проверки требуют совместимость загруженных весов с архитектурой и способ извлечения признаков.

Дальнейшая работа предусматривает согласование предобработки с требованиями модели и сравнение замороженного энкодера с дообучением выбранных блоков. При изменении предобработки baseline необходимо пересчитать в тех же условиях: это позволит отделить эффект обработки изображений от эффекта адаптации. Сравнение планируется проводить на одинаковых внешних разбиениях по участникам, с подбором параметров и ранней остановкой только внутри обучающей части.

Окончательный вывод о сравнении режимов адаптации будет сформулирован после выполнения запланированных экспериментов.

Список литературы

[1] de Faria, Danilo Donizete et al. *Structural brain analysis in focal upper limb dystonia.* Scientific Reports. 2026. DOI: 10.1038/s41598-026-39542-z.

[2] Guo, Qingwei; Luo, Yaru; Du, Naixuan et al. *Multimodal MRI reveals structural and functional alterations in isolated cervical dystonia: associations with motor severity and affective symptoms.* Frontiers in Neurology. 2026. DOI: 10.3389/fneur.2026.1771144.

[3] Marques Paulo, Artur José; Waugh, Jeff L.; Winkler, Anderson M. et al. *Striatal compartment and white matter alterations in focal dystonia Subtypes: An MRI study.* Parkinsonism & Related Disorders. 2025. DOI: 10.1016/j.parkreldis.2025.108096.

[4] Yiğit, Hüseyin; Gökoğlu, Abdulkerim. *Distinct thalamic volumetric profiles in cervical and upper limb dystonia.* Arquivos de Neuro-Psiquiatria. 2026. DOI: 10.1055/s-0046-1825521.

[5] Wu, Yunhao; Wang, Tao; Ding, Qiong et al. *Cortical and Subcortical Structural Abnormalities in Patients With Idiopathic Cervical and Generalized Dystonia.* Frontiers in Neuroimaging. 2022. DOI: 10.3389/fnimg.2022.807850.

[6] Valeriani, Davide; Simonyan, Kristina. *A microstructural neural network biomarker for dystonia diagnosis identified by a DystoniaNet deep learning platform.* Proceedings of the National Academy of Sciences. 2020. DOI: 10.1073/pnas.2009165117.

[7] Li, Zhihao; Prudente, Cecília N.; Stilla, Randall et al. *Alterations of resting-state fMRI measurements in individuals with cervical dystonia.* Human Brain Mapping. 2017. DOI: 10.1002/hbm.23651.

[8] Pan, Pan; Wei, Shubao; Ou, Yangpan et al. *Reduced Global-Brain Functional Connectivity and Its Relationship With Symptomatic Severity in Cervical Dystonia.* Frontiers in Neurology. 2020. DOI: 10.3389/fneur.2019.01358.

[9] Tak, Divyanshu; Garomsa, Biniam A.; Zapaishchykova, Anna et al. *A generalizable foundation model for analysis of human brain MRI.* Nature Neuroscience. 2026. DOI: 10.1038/s41593-026-02202-6.

[10] Cox, Joseph; Liu, Peng; Stolte, Skylar E. et al. *BrainSegFounder: Towards 3D foundation models for neuroimage segmentation.* Medical Image Analysis. 2024. DOI: 10.1016/j.media.2024.103301.

[11] Barbano, Carlo Alberto; Brunello, Matteo; Dufumier, Benoit et al. *Anatomical foundation models for brain MRIs.* Pattern Recognition Letters. 2026. DOI: 10.1016/j.patrec.2025.11.028.

[12] Xu, Tony; Hosseini, Sepehr; Anderson, Chris et al. *A generalizable 3D framework and model for self-supervised learning in medical imaging.* npj Digital Medicine. 2025. DOI: 10.1038/s41746-025-02035-w.

[13] Wu, Yizhou; Wang, Shansong; Li, Yuheng et al. *BrainDINO: A Brain MRI Foundation Model for Generalizable Clinical Representation Learning.* 2026. https://arxiv.org/abs/2604.27277.

[14] Wald, Tassilo; Ulrich, Constantin; Suprijadi, Jonathan et al. *An OpenMind for 3D Medical Vision Self-supervised Learning.* Proceedings of the IEEE/CVF International Conference on Computer Vision. 2025. https://openaccess.thecvf.com/content/ICCV2025/html/Wald_An_OpenMind_for_3D_Medical_Vision_Self-supervised_Learning_ICCV_2025_paper.html.

[15] Chen, Sihong; Ma, Kai; Zheng, Yefeng. *Med3D: Transfer Learning for 3D Medical Image Analysis.* 2019. https://arxiv.org/abs/1904.00625.

[16] Zhou, Zongwei; Sodha, Vatsal; Pang, Jiaxuan et al. *Models Genesis.* Medical Image Analysis. 2021. DOI: 10.1016/j.media.2020.101840.

[17] Tang, Yucheng; Yang, Dong; Li, Wenqi et al. *Self-Supervised Pre-Training of Swin Transformers for 3D Medical Image Analysis.* Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2022. DOI: 10.1109/CVPR52688.2022.02007.

[18] Dosovitskiy, Alexey et al. *An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale.* International Conference on Learning Representations. 2021. https://arxiv.org/abs/2010.11929.

[19] Kumar, Ananya; Raghunathan, Aditi; Jones, Robbie et al. *Fine-Tuning can Distort Pretrained Features and Underperform Out-of-Distribution.* International Conference on Learning Representations. 2022. https://arxiv.org/abs/2202.10054.

[20] Varoquaux, Gaël. *Cross-validation failure: Small sample sizes lead to large error bars.* NeuroImage. 2018. DOI: 10.1016/j.neuroimage.2017.06.061.

[21] Wen, Junhao; Thibeau-Sutre, Elina; Diaz-Melo, Mauricio et al. *Convolutional neural networks for classification of Alzheimer's disease: Overview and reproducible evaluation.* Medical Image Analysis. 2020. DOI: 10.1016/j.media.2020.101694.

[22] Rosenblatt, Matthew; Tejavibulya, Link; Jiang, Rongtao et al. *Data leakage inflates prediction performance in connectome-based machine learning models.* Nature Communications. 2024. DOI: 10.1038/s41467-024-46150-w.

[23] Snoek, Lukas; Miletić, Steven; Scholte, H. Steven. *How to control for confounds in decoding analyses of neuroimaging data.* NeuroImage. 2019. DOI: 10.1016/j.neuroimage.2018.09.074.

[24] Vabalas, Andrius; Gowen, Emma; Poliakoff, Ellen et al. *Machine learning algorithm validation with a limited sample size.* PLOS ONE. 2019. DOI: 10.1371/journal.pone.0224365.

[25] Ojala, Markus; Garriga, Gemma C. *Permutation Tests for Studying Classifier Performance.* Journal of Machine Learning Research. 2010. https://www.jmlr.org/beta/papers/v11/ojala10a.html.

[26] Marek, Scott et al. *Reproducible brain-wide association studies require thousands of individuals.* Nature. 2022. DOI: 10.1038/s41586-022-04492-9.

[27] Yagis, Ekin; Atnafu, Selamawet Workalemahu; García Seco de Herrera, Alba et al. *Effect of data leakage in brain MRI classification using 2D convolutional neural networks.* Scientific Reports. 2021. DOI: 10.1038/s41598-021-01681-w.

[28] Navarro-Gonzalez, Rafael; Aja-Fernandez, Santiago; Planchuelo-Gomez, Alvaro et al. *Cross-Scanner Reliability of Brain MRI Foundation Model Embeddings: A Travelling-Heads Study.* medRxiv. 2026. DOI: 10.64898/2026.03.23.26348808.

[29] Albanese, Alberto et al. *Definition and Classification of Dystonia.* Movement Disorders. 2025. DOI: 10.1002/mds.30220.

[30] *Upper limb dystonia, cervical dystonia and healthy controls dataset.* DOI: 10.18112/openneuro.ds006395.v1.0.8.